



# Time Series Forecasting

Développez un outil de prévision de la consommation d'énergie



# OBJECTIF

Créer un outil de prédiction de la consommation d'énergie de nos clients et anticiper les besoins du marché en utilisant des réseaux neuronaux récurrents

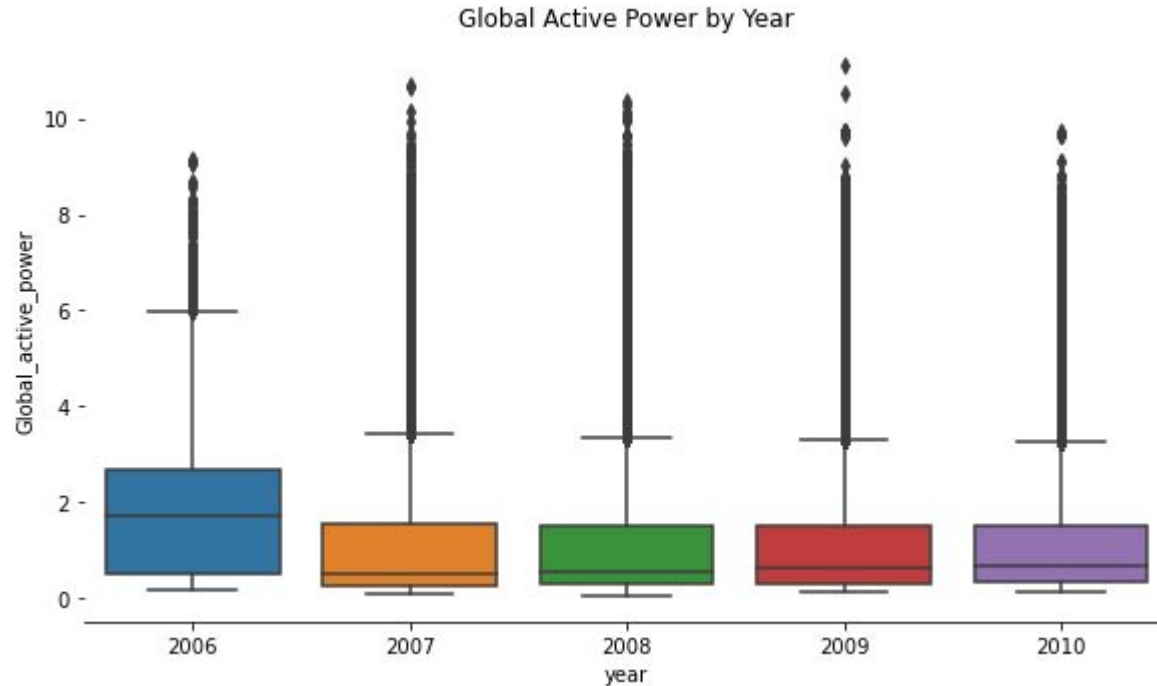


## Le dataset

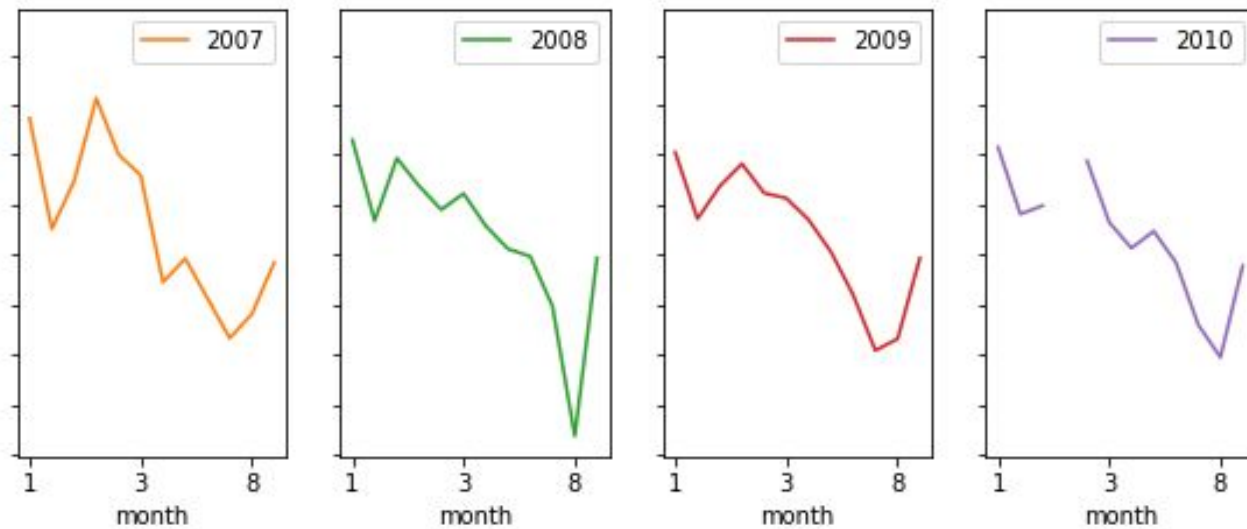
Ce dataset contient la consommation électrique d'un seul foyer par minute, sur une période de 4 ans, soit 3 millions de valeurs entre décembre 2006 , et novembre 2010.





Il y a différentes mesures électriques (volt, ampère, kilowatt) mais nous restons concentré sur notre cible à prédire : la colonne “global activy power” qui elle, est en kilowatt.

# Notre cible : Global active power



Global activity power par années







## Les différentes étapes pour modéliser une série temporelle

- Set index sur le datetime
- Split le dataset (train / test)
- Normaliser les features
- Convertir les valeurs en matrice
- Reshape en  $X=t$  and  $Y=t+1$ .
- Reshape input en 3D : (sample size, time steps, features)



## Résultats obtenus avec LSTM

- Resample par jour
- Variation de la sequence length
- Variation du Batch size
- Test en resample par heure



```
model = Sequential()  
model.add(Input(shape=(sequence_length, num_features)))  
model.add(LSTM(14, return_sequences=False, activation='tanh'))  
model.add(Dense(1, activation='linear'))
```

```
sampling_rate = 1  
sequence_length = 7  
stride = 1  
batch_size = 252  
shuffle = False
```

loss: 0.4181 - mae: 0.4785

```
sampling_rate = 1  
sequence_length = 14  
stride = 1  
batch_size = 252  
shuffle = False
```

loss: 0.3659 - mae: 0.4479

```
sampling_rate = 1  
sequence_length = 28  
stride = 1  
batch_size = 252  
shuffle = False
```

loss: 0.3862 - mae: 0.4577

## Variation Batch size

```
sampling_rate = 1  
sequence_length = 14  
stride = 1  
batch_size = 32  
shuffle = False
```

loss: 0.3513 - mae: 0.4267

```
sampling_rate = 1  
sequence_length = 14  
stride = 1  
batch_size = 64  
shuffle = False
```

loss: 0.3476 - mae: 0.4232

```
sampling_rate = 1  
sequence_length = 14  
stride = 1  
batch_size = 128  
shuffle = False
```

loss: 0.3559 - mae: 0.4202

```
sampling_rate = 1  
sequence_length = 14  
stride = 1  
batch_size = 256  
shuffle = False
```

loss: 0.3701 - mae: 0.4405

```
sampling_rate = 1  
sequence_length = 14  
stride = 1  
batch_size = 512  
shuffle = False
```

loss: 0.3520 - mae: 0.4268

## Modification LSTM

```
model = Sequential()  
model.add(Input(shape=(sequence_length, num_features)))  
model.add(LSTM(28, return_sequences=False, activation='tanh'))  
model.add(Dense(1, activation='linear'))
```

loss: 0.3377 - mae: 0.4150

## Resample par heure

```
sampling_rate = 1  
sequence_length = 24  
stride = 1  
batch_size = 512  
shuffle = False
```

loss: 0.2870 - mae: 0.3797



# Conclusion

- Meilleurs résultats en resampling par heure
- Difficultés de compréhension du preprocessing pour les time series en DL
- Next step : Continuer les tests avec LSTM et GRU, améliorer le modèle en jouant sur le preprocessing et les hyperparamètres